MODULE 1. HIỂU ĐÚNG VỀ CÔNG NGHỆ DEEPFAKE

1.1. Deepfake là gì?

Deepfake là thuật ngữ dùng để chỉ nội dung hình ảnh, âm thanh hoặc video được tạo mới hay thao túng bằng các kỹ thuật trí tuệ nhân tạo (AI), đặc biệt là học sâu (Deep Learning), nhằm mô phỏng khuôn mặt, giọng nói, biểu cảm hoặc hành động của con người. Công nghệ này có thể khiến một người xuất hiện, nói hoặc thực hiện hành động trong một nội dung số dù sự việc đó không diễn ra như cách nội dung thể hiện.

Ví dụ, một video có thể mô phỏng khuôn mặt và giọng nói của một người nổi tiếng để khiến người xem tin rằng họ đang quảng cáo một sản phẩm. Tương tự, một đoạn ghi âm có thể mô phỏng giọng nói của người thân để yêu cầu chuyển tiền. Trong những trường hợp này, nội dung được tạo ra có thể trông hoặc nghe giống thật, nhưng không phản ánh chính xác sự kiện thực tế.

Để hiểu đúng Deepfake, cần phân biệt công nghệ này với các hình thức chỉnh sửa nội dung thông thường. Việc cắt ghép video, điều chỉnh độ sáng, thêm bộ lọc hoặc loại bỏ tạp âm không mặc nhiên tạo thành Deepfake. Điểm đặc trưng của Deepfake là việc sử dụng kỹ thuật AI để tạo sinh hoặc thao túng nội dung, thường nhằm mô phỏng danh tính hay đặc điểm của một người.

Deepfake có ba đặc điểm đáng chú ý:

- **Khả năng mô phỏng:** AI có thể tái tạo hoặc biến đổi các đặc điểm như khuôn mặt, giọng nói, biểu cảm và chuyển động.
- **Tính chân thực:** Nội dung đầu ra có thể tạo cảm giác tự nhiên, khiến người tiếp nhận khó nhận biết bằng quan sát thông thường.
- **Tính đa dạng về mục đích:** Deepfake có thể phục vụ sáng tạo, giải trí, giáo dục, nhưng cũng có thể bị lợi dụng để giả mạo danh tính, lừa đảo hoặc phát tán thông tin sai lệch.

Cần lưu ý rằng không phải mọi nội dung do AI tạo ra đều là Deepfake theo nghĩa hẹp, cũng không phải mọi Deepfake đều được tạo ra với mục đích gây hại. Việc đánh giá cần xem xét cách nội dung được tạo ra, điều gì đã bị thay đổi, bối cảnh sử dụng và mức độ minh bạch đối với người tiếp nhận.

1.2. Nguyên lý hoạt động của công nghệ Deepfake

Deepfake được tạo ra bằng các hệ thống AI có khả năng học và xử lý đặc điểm của dữ liệu. Thay vì phải chỉnh sửa thủ công từng chi tiết, người tạo có thể sử dụng mô hình AI để tạo mới hoặc biến đổi hình ảnh, âm thanh và video theo mục đích cụ thể.

Ở mức khái quát, quá trình này gồm ba bước:

Bước 1. Dữ liệu đầu vào

Hệ thống tiếp nhận dữ liệu phù hợp với nhiệm vụ, chẳng hạn như ảnh khuôn mặt, video, đoạn ghi âm hoặc dữ liệu giọng nói. Chất lượng, số lượng và đặc điểm của dữ liệu có thể ảnh hưởng đến kết quả tạo sinh.

Bước 2. Mô hình AI xử lý

Mô hình học máy hoặc học sâu xử lý dữ liệu để học hoặc khai thác những đặc điểm cần thiết. Tùy phương pháp, hệ thống có thể mô phỏng giọng nói, biến đổi khuôn mặt, tạo hình ảnh tổng hợp hoặc đồng bộ chuyển động môi với âm thanh.

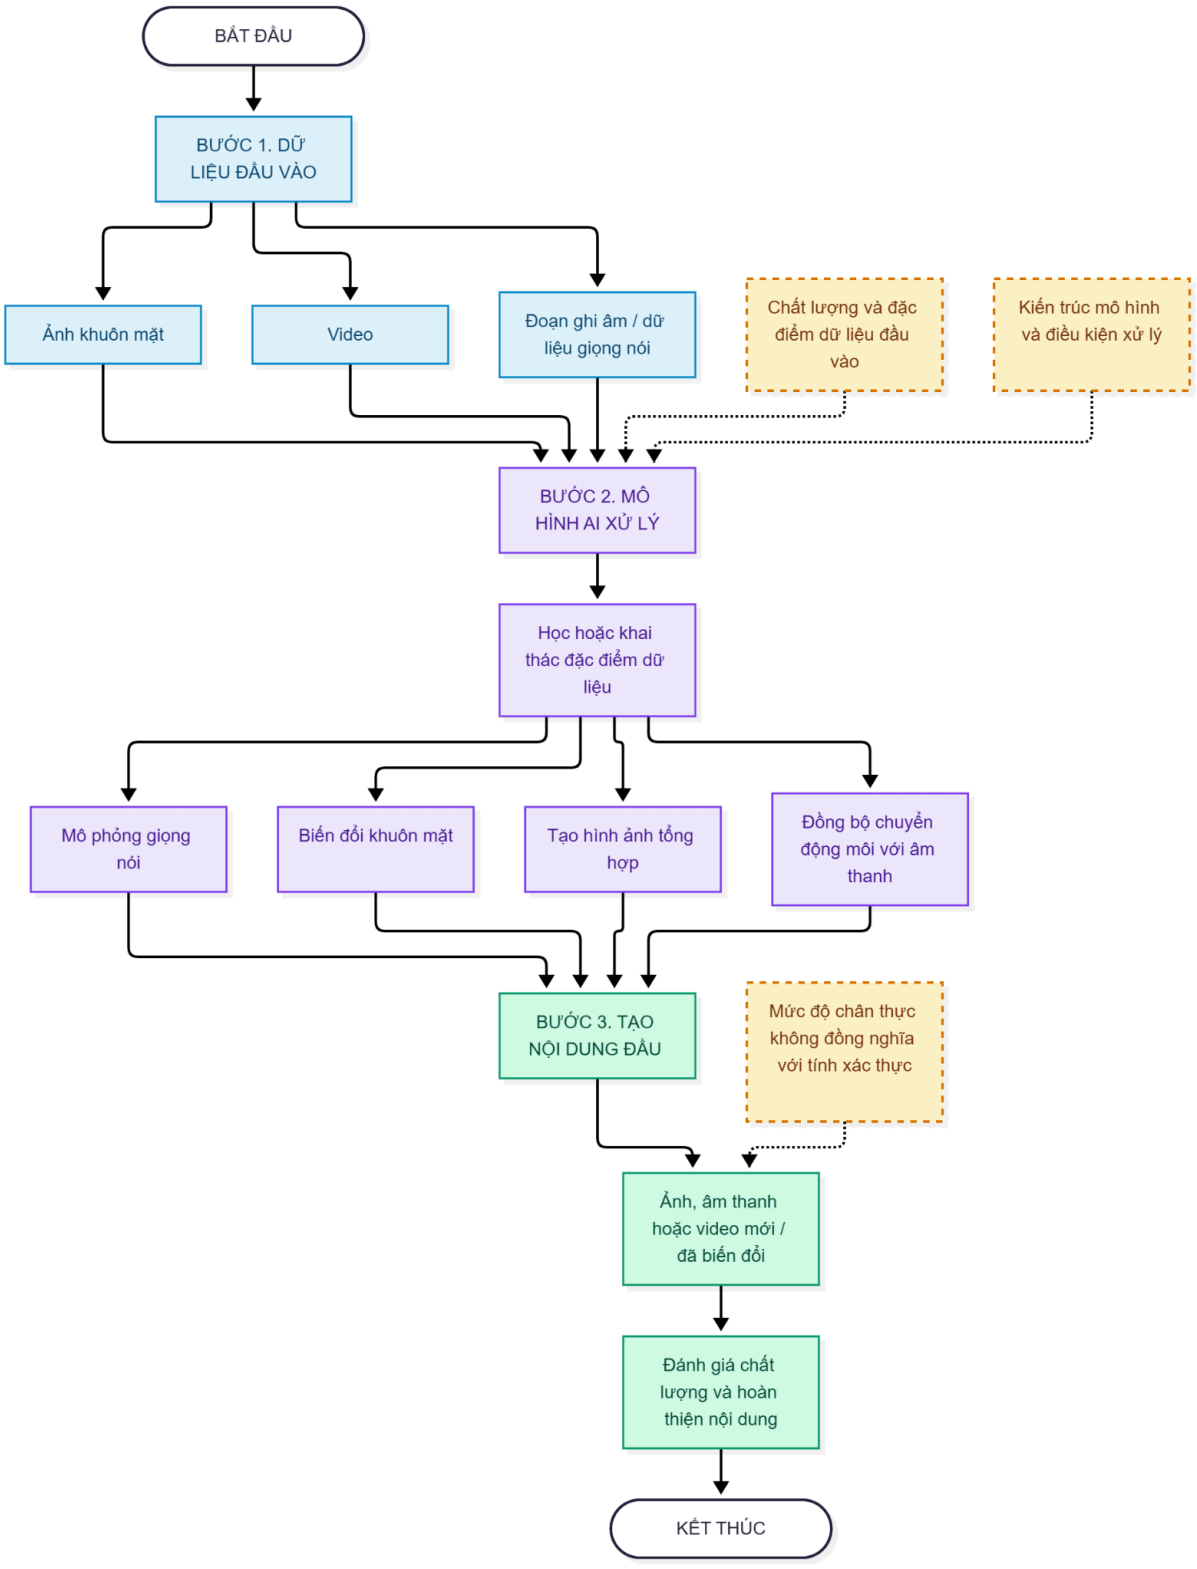
Bước 3. Tạo nội dung đầu ra

Hệ thống tạo ra nội dung mới hoặc biến đổi nội dung có sẵn. Kết quả có thể là một bức ảnh, đoạn ghi âm hoặc video mang những đặc điểm giống người thật.

Quy trình trên chỉ mang tính khái quát, bởi mỗi loại Deepfake có thể sử dụng phương pháp và kiến trúc AI khác nhau. Chất lượng đầu ra phụ thuộc vào mô hình, dữ liệu đầu vào, điều kiện xử lý và các bước hoàn thiện nội dung.

Điểm quan trọng là quá trình tạo Deepfake có thể được tự động hóa ở mức đáng kể. Vì vậy, người tạo không nhất thiết phải có kỹ năng chỉnh sửa hình ảnh hoặc âm thanh chuyên sâu mới có thể tạo ra nội dung mô phỏng. Khi công nghệ phát triển, sản phẩm tạo sinh cũng có thể ngày càng chân thực, làm tăng khó khăn trong việc xác minh chỉ bằng mắt hoặc tai.

Tuy nhiên, **nội dung càng chân thực không đồng nghĩa với nội dung càng đáng tin cậy**. Mức độ chân thực là đặc điểm của sản phẩm, trong khi tính xác thực liên quan đến việc nội dung có phản ánh đúng người, lời nói hoặc sự kiện được thể hiện hay không.



Hình 1. Nguyên lý hoạt động của Công nghệ Deepfake

1.3. Các hình thức Deepfake phổ biến

Deepfake thường được phân loại theo loại nội dung bị tạo sinh hoặc thao túng. Ba hình thức phổ biến là Deepfake hình ảnh, Deepfake âm thanh và Deepfake video.

Hình thức	Đặc điểm	Ví dụ minh họa
Deepfake hình ảnh	Tạo mới hoặc biến đổi khuôn mặt, ngoại hình hay đặc điểm của một người trong ảnh.	Một bức ảnh khiến người xem tin rằng một cá nhân đã có mặt tại địa điểm mà họ thực tế chưa từng đến.
Deepfake âm thanh	Tạo hoặc mô phỏng giọng nói, cách phát âm và đặc điểm âm thanh của một người.	Một đoạn ghi âm mô phỏng giọng người thân để yêu cầu chuyển tiền khẩn cấp.
Deepfake video	Tạo hoặc biến đổi khuôn mặt, biểu cảm, chuyển động hoặc lời nói trong video.	Một video mô phỏng một cá nhân phát ngôn điều mà họ chưa từng nói.

Deepfake hình ảnh có thể làm thay đổi diện mạo của một người hoặc tạo ra hình ảnh về một tình huống chưa từng xảy ra. Khi hình ảnh được chia sẻ mà không có thông tin về nguồn gốc, người xem có thể nhầm lẫn nội dung tổng hợp với bằng chứng ghi lại sự kiện thật.

Deepfake âm thanh khai thác khả năng mô phỏng đặc điểm giọng nói. Do con người thường dựa vào giọng nói quen thuộc để nhận biết người thân hoặc đồng nghiệp, loại nội dung này có thể bị lợi dụng trong các tình huống lừa đảo, đặc biệt khi đi kèm yêu cầu khẩn cấp hoặc gây áp lực tâm lý.

Deepfake video có thể kết hợp nhiều yếu tố như khuôn mặt, chuyển động, biểu cảm và âm thanh. Chẳng hạn, video có thể khiến một người trông như đang nói một câu cụ thể dù họ chưa từng phát ngôn như vậy. Do kết hợp cả hình ảnh chuyển động và âm thanh, loại nội dung này có thể tạo cảm giác thuyết phục đối với người xem.

Trên thực tế, một sản phẩm có thể kết hợp nhiều hình thức Deepfake. Video giả mạo có thể đồng thời sử dụng khuôn mặt được biến đổi và giọng nói được tạo sinh. Vì vậy, việc kiểm tra riêng hình ảnh hoặc âm thanh có thể chưa đủ để đánh giá toàn bộ nội dung.

1.4. Lợi ích và rủi ro của công nghệ Deepfake

Deepfake là một công nghệ có nhiều khả năng ứng dụng. Tác động của nó phụ thuộc vào mục đích sử dụng, mức độ minh bạch, sự đồng ý của người liên quan và hậu quả đối với những người bị ảnh hưởng.

1.4.1. Lợi ích và ứng dụng

Trong lĩnh vực sáng tạo và giải trí, Deepfake có thể hỗ trợ tạo hiệu ứng hình ảnh, mô phỏng nhân vật hoặc xây dựng những sản phẩm truyền thông khó thực hiện bằng phương pháp thông thường.

Trong giáo dục và đào tạo, công nghệ mô phỏng có thể được sử dụng để xây dựng tình huống học tập, tái hiện nhân vật lịch sử hoặc minh họa những kịch bản giả định. Trong sản xuất nội dung, AI cũng có thể hỗ trợ một số công việc liên quan đến hình ảnh và âm thanh.

Những ứng dụng này cần được triển khai có trách nhiệm, đặc biệt khi sử dụng hình ảnh hoặc giọng nói của người thật. Việc công khai tính chất tổng hợp của nội dung và tôn trọng quyền của người liên quan giúp hạn chế nguy cơ gây hiểu nhầm hoặc xâm phạm quyền riêng tư.

1.4.2. Những rủi ro khi Deepfake bị lạm dụng

Giả mạo danh tính và lừa đảo: Kẻ gian có thể sử dụng hình ảnh hoặc giọng nói mô phỏng một người để tạo lòng tin, yêu cầu chuyển tiền, lấy thông tin đăng nhập hoặc thực hiện hành vi gian lận.

Phát tán thông tin sai lệch: Nội dung giả mạo có thể khiến công chúng tin rằng một cá nhân đã phát ngôn hoặc thực hiện hành động mà họ không thực sự làm. Khi

được chia sẻ rộng rãi, nội dung này có thể gây hiểu lầm và ảnh hưởng đến nhận thức của cộng đồng.

Xâm phạm quyền riêng tư: Hình ảnh, giọng nói hoặc dữ liệu cá nhân có thể bị sử dụng để tạo nội dung mà người liên quan không biết hoặc không đồng ý. Việc phát tán nội dung như vậy có thể gây tổn hại về tinh thần, danh tiếng và các mối quan hệ xã hội.

Tổn hại danh tiếng: Một nội dung giả mạo có thể khiến cá nhân bị hiểu lầm, quấy rối hoặc mất uy tín. Ngay cả khi nội dung được đính chính, thông tin ban đầu vẫn có thể tiếp tục được lưu giữ và chia sẻ.

Suy giảm niềm tin vào thông tin số: Khi nội dung thật và giả ngày càng khó phân biệt, người dùng có thể nghi ngờ cả những hình ảnh, đoạn ghi âm hoặc video xác thực. Điều này khiến việc sử dụng bằng chứng số để xác minh sự kiện trở nên phức tạp hơn.

Các rủi ro trên cho thấy Deepfake không chỉ là vấn đề kỹ thuật. Đây còn là vấn đề liên quan đến danh tính số, quyền riêng tư, độ tin cậy của thông tin và trách nhiệm của người tạo, người đăng tải cũng như người chia sẻ nội dung.

1.5. Giới hạn của việc nhận diện Deepfake

Không phải lúc nào người dùng cũng có thể xác định nội dung là thật hay giả bằng cách quan sát hình ảnh hoặc lắng nghe âm thanh. Có ba giới hạn quan trọng cần ghi nhớ.

1.5.1. Dấu hiệu bất thường không phải bằng chứng kết luận

Một số nội dung Deepfake có thể xuất hiện các dấu hiệu như chuyển động môi thiếu tự nhiên, ánh sáng không đồng nhất, biểu cảm bất thường hoặc âm thanh không khớp với hình ảnh. Tuy nhiên, những dấu hiệu này không chỉ xuất hiện ở Deepfake. Chất lượng ghi hình thấp, quá trình nén tệp, đường truyền không ổn định hoặc chỉnh sửa thông thường cũng có thể tạo ra hiện tượng tương tự.

Ngược lại, một nội dung không có dấu hiệu bất thường rõ ràng vẫn có thể đã được tạo sinh hoặc thao túng bằng AI. Do đó, người dùng không nên kết luận nội dung là thật chỉ vì hình ảnh rõ nét, giọng nói tự nhiên hoặc chuyển động trông hợp lý.

1.5.2. Công cụ phát hiện có thể đưa ra kết quả sai

Các công cụ phát hiện Deepfake sử dụng những phương pháp và tiêu chí phân tích khác nhau. Kết quả có thể phụ thuộc vào loại nội dung, chất lượng tệp, dữ liệu mà mô hình đã được huấn luyện và điều kiện sử dụng.

Một công cụ có thể đánh dấu nhầm nội dung thật là giả, bỏ sót nội dung giả hoặc không đưa ra kết quả rõ ràng. Nếu công cụ cung cấp điểm số, người dùng cũng cần hiểu điểm số đó biểu thị điều gì. Không nên tự động diễn giải điểm số thành xác suất nội dung là giả nếu chưa có căn cứ cho cách diễn giải ấy.

Vì vậy, công cụ phát hiện chỉ nên được xem là nguồn hỗ trợ đánh giá, không phải căn cứ duy nhất để kết luận tính xác thực của nội dung.

1.5.3. Tính xác thực của nội dung khác với ý định của người đăng

Việc xác định một hình ảnh, âm thanh hoặc video đã được tạo sinh hay chỉnh sửa không tự động chứng minh người tạo hoặc người chia sẻ có ý định lừa đảo. Nội dung có thể được sử dụng cho mục đích sáng tạo, châm biếm, giáo dục hoặc nghiên cứu, miễn là việc sử dụng đáp ứng các yêu cầu liên quan.

Ngược lại, một nội dung trông bình thường cũng không bảo đảm người gửi là đúng người mà họ tự nhận hoặc thông tin được cung cấp là chính xác.

Do đó, cần phân biệt hai câu hỏi:

- **Nội dung có xác thực không?** Cần xem xét nguồn gốc, bằng chứng và mức độ phù hợp giữa nội dung với sự kiện được mô tả.
- **Người tạo hoặc chia sẻ có đáng tin cậy không?** Cần xem xét danh tính, bối cảnh, mục đích và hành vi của người đó bằng những căn cứ phù hợp.

Hai câu hỏi này có liên quan nhưng không đồng nhất. Đánh giá thận trọng đòi hỏi phải xem xét nhiều nguồn bằng chứng độc lập thay vì dựa vào một dấu hiệu kỹ thuật hoặc cảm giác chủ quan.

1.6. Nguyên tắc tiếp cận Deepfake một cách có trách nhiệm

Khi tiếp nhận hình ảnh, âm thanh hoặc video trên môi trường số, người dùng cần tránh hai thái cực: tin tưởng tuyệt đối vào nội dung trông giống thật và mặc định mọi nội dung do AI tạo ra đều có hại.

Một cách tiếp cận phù hợp là xem xét đồng thời ba yếu tố:

Nguồn gốc: Nội dung xuất phát từ đâu? Tài khoản đăng tải có đáng tin cậy không? Có nguồn độc lập nào xác nhận thông tin hay không?

Bối cảnh: Nội dung có phù hợp với thời gian, địa điểm và sự kiện được mô tả không? Có dấu hiệu cho thấy nội dung đã bị cắt khỏi ngữ cảnh hoặc diễn giải sai không?

Bằng chứng độc lập: Có thể đối chiếu thông tin với nguồn khác hay xác minh danh tính qua một kênh riêng biệt không?

Đặc biệt, khi nội dung đi kèm yêu cầu chuyển tiền, cung cấp mã OTP, thông tin đăng nhập hoặc dữ liệu cá nhân nhạy cảm, người dùng nên tạm dừng thực hiện yêu cầu và xác minh qua kênh độc lập đã biết trước. Chẳng hạn, nếu nhận được cuộc gọi có giọng nói giống người thân nhưng yêu cầu chuyển tiền gấp, hãy gọi lại số điện thoại đã lưu hoặc xác nhận trực tiếp qua một kênh khác thay vì chỉ dựa vào giọng nói trong cuộc gọi.

Cách tiếp cận này phù hợp với định hướng minh bạch nội dung số được NIST đề cập: việc đánh giá nội dung tổng hợp cần dựa trên nhiều tín hiệu và bối cảnh, đồng thời thừa nhận giới hạn của từng phương pháp kỹ thuật.

Tóm lại, Deepfake là công nghệ AI có khả năng tạo mới hoặc thao túng hình ảnh, âm thanh và video với mức độ chân thực ngày càng cao. Công nghệ này có thể

phục vụ nhiều mục đích hữu ích, nhưng cũng tạo ra rủi ro đối với danh tính, quyền riêng tư, danh tiếng và độ tin cậy của thông tin. Hiểu đúng Deepfake không có nghĩa là phải tự mình nhận diện được mọi nội dung giả mạo, mà là biết giới hạn của quan sát thông thường, không vội kết luận và chủ động kiểm chứng thông tin trước khi tin tưởng hoặc chia sẻ.

Tài liệu tham khảo

1. Chandra, B., Dunietz, J., Roberts, K., Lee, Y., Fontana, P., & Awad, G. (2024). *Reducing Risks Posed by Synthetic Content: An Overview of Technical Approaches to Digital Content Transparency* (NIST AI 100-4). National Institute of Standards and Technology. https://doi.org/10.6028/NIST.AI.100-4

2. Chesney, R., & Citron, D. K. (2019). Deep fakes: A looming challenge for privacy, democracy, and national security. *California Law Review, 107*(6), 1753-1820. https://doi.org/10.15779/Z38RV0D15J