MODULE 4. THỰC HÀNH ỨNG PHÓ VÀ SỬ DỤNG CÔNG CỤ PHÁT HIỆN

Ở các module trước, người học đã tìm hiểu khái niệm Deepfake, cách nhận diện và kiểm chứng nội dung, cũng như những biện pháp bảo vệ thông tin cá nhân. Module 4 chuyển từ việc hiểu kiến thức sang vận dụng: khi gặp một hình ảnh, video, đoạn ghi âm hoặc yêu cầu có dấu hiệu giả mạo, người học cần biết dừng lại, kiểm tra, lựa chọn công cụ phù hợp và quyết định cách xử lý an toàn.

Một nguyên tắc xuyên suốt của module là công cụ phát hiện chỉ hỗ trợ quá trình đánh giá, không phải căn cứ duy nhất để kết luận nội dung là thật hay giả. Kết quả cần được xem xét cùng nguồn đăng tải, bối cảnh, bằng chứng độc lập và mức độ rủi ro. Đồng thời, người học cần bảo vệ quyền riêng tư khi sử dụng dịch vụ phân tích trực tuyến.

Sau khi hoàn thành module, người học có thể lựa chọn công cụ theo loại nội dung, thực hiện quy trình kiểm tra cơ bản, đọc hiểu kết quả và giới hạn của công cụ, xác định bằng chứng cần kiểm chứng thêm, cũng như lưu giữ và báo cáo nội dung đáng ngờ theo cách hạn chế gây hại.

1. Quy trình ứng phó khi gặp nội dung Deepfake đáng ngờ

Khi gặp một hình ảnh, video hoặc đoạn âm thanh có dấu hiệu bị giả mạo, người dùng không nên lập tức chia sẻ, chuyển tiền hoặc làm theo yêu cầu trong nội dung đó. Trước hết, hãy xác định nội dung có đang thúc giục mình thực hiện hành động rủi ro hay không. Nội dung giả mạo có thể được sử dụng để lan truyền thông tin sai lệch, mạo danh người quen, yêu cầu cung cấp dữ liệu cá nhân hoặc thúc đẩy chuyển tiền.

Đặc biệt, kẻ lừa đảo có thể sử dụng công nghệ nhân bản giọng nói để giả danh người thân, tạo cảm giác khẩn cấp và yêu cầu giữ bí mật. Vì vậy, nghe thấy giọng nói quen thuộc hoặc nghe người gọi nhắc đến thông tin gia đình không đủ để xác nhận danh tính.

1.1. 5 bước ứng phó

1.1.1. Tạm dừng hành động

Không vội chuyển tiền, cung cấp mật khẩu, mã OTP, mã xác thực hay thông tin cá nhân. Không chia sẻ lại nội dung đáng ngờ như thể đó là thông tin đã được xác thực. Nếu người liên hệ gây áp lực phải hành động ngay hoặc yêu cầu giữ bí mật, hãy xem đó là dấu hiệu cần kiểm tra thận trọng hơn.

1.1.2. Kiểm tra nguồn và bối cảnh

Xác định tài khoản đăng tải, thời điểm nội dung xuất hiện, nguồn ban đầu và mục đích của thông điệp. Tìm xem nội dung có xuất hiện ở kênh chính thức hay nguồn đáng tin cậy khác không. Với yêu cầu liên quan đến danh tính hoặc tiền bạc, hãy xác minh qua một kênh liên lạc độc lập, chẳng hạn chủ động gọi lại số điện thoại đã biết thay vì tiếp tục dùng kênh mà người đáng ngờ vừa cung cấp.

1.1.3. Sử dụng công cụ khi phù hợp

Nếu cần kiểm tra kỹ thuật, hãy lựa chọn công cụ có khả năng phân tích loại nội dung đang nghi ngờ. Trước khi tải tệp lên, kiểm tra điều kiện sử dụng và chính sách xử lý dữ liệu. Không nên tải tài liệu nội bộ, hình ảnh riêng tư, dữ liệu cá nhân nhạy cảm hoặc nội dung chưa được phép chia sẻ lên dịch vụ trực tuyến.

1.1.4. Đánh giá bằng chứng

Đối chiếu kết quả công cụ với nguồn độc lập, bối cảnh và thông tin liên quan. Nếu kết quả mâu thuẫn hoặc chưa đủ căn cứ, hãy giữ trạng thái “chưa xác minh” thay vì khẳng định nội dung là thật hay giả. Không để một nhãn hoặc điểm số duy nhất quyết định hành động có thể gây thiệt hại.

1.1.5. Lựa chọn cách xử lý

Không tiếp tục thực hiện yêu cầu đáng ngờ. Khi phù hợp, lưu giữ bằng chứng cần thiết, báo cáo nội dung trên nền tảng và tìm kiếm hỗ trợ nếu có nguy cơ lừa đảo, thiệt hại tài chính hoặc xâm phạm quyền riêng tư. Nếu thiệt hại đã xảy ra, cần xử lý trực tiếp với tổ chức liên quan; báo cáo trên nền tảng không thay thế các bước bảo vệ tài khoản hay liên hệ ngân hàng.

Quy trình này không yêu cầu người học phải xác định chính xác mọi Deepfake. Mục tiêu quan trọng hơn là biết khi nào cần dừng lại, kiểm chứng thêm và lựa chọn hành động giảm thiểu rủi ro.

Bước	Câu hỏi tự kiểm tra	Hành động chính
1. Tạm dừng	Nội dung có yêu cầu tôi làm ngay điều gì nhạy cảm không?	Không chuyển tiền, không cung cấp mã hoặc dữ liệu, không vội chia sẻ.
2. Kiểm tra nguồn	Ai đăng, nguồn ban đầu ở đâu và bối cảnh có hợp lý không?	Kiểm tra nguồn và xác minh qua kênh độc lập.
3. Dùng công cụ	Công cụ có hỗ trợ đúng loại nội dung này không? Dữ liệu có nhạy cảm không?	Chọn công cụ phù hợp và kiểm tra chính sách dữ liệu.
4. Đánh giá	Có bằng chứng độc lập nào hỗ trợ hoặc mâu thuẫn với kết quả không?	Đối chiếu thông tin; giữ trạng thái chưa xác minh khi chưa đủ căn cứ.
5. Xử lý	Có cần lưu bằng chứng, báo cáo hoặc tìm trợ giúp không?	Ngừng hành động đáng ngờ và lựa chọn biện pháp giảm thiểu rủi ro.

2. Lựa chọn và sử dụng công cụ phát hiện Deepfake

Công cụ phát hiện Deepfake sử dụng các phương pháp phân tích tự động để tìm kiếm những đặc điểm có thể liên quan đến nội dung do AI tạo ra hoặc nội dung bị thao túng. Tuy nhiên, các công cụ không có phạm vi giống nhau. Công cụ được thiết kế để phân tích video có thể không đánh giá được giọng nói; công cụ nhận diện nội dung do AI tạo ra cũng không đồng nghĩa với khả năng phát hiện mọi dạng chỉnh sửa hoặc giả mạo.

Trước khi lựa chọn công cụ, người học cần xem xét ba yếu tố: loại nội dung cần kiểm tra, khả năng và giới hạn của công cụ, mức độ nhạy cảm của dữ liệu đầu vào.

2.1. Một số công cụ tham khảo

2.1.1. Deepfake-o-meter Scanner

Theo định hướng trong tài liệu module, Deepfake-o-meter Scanner tập trung vào việc phân tích video để tìm dấu hiệu thao túng khuôn mặt. Công cụ không kiểm tra việc giả mạo giọng nói và kết quả chỉ thể hiện khả năng nội dung có thể là Deepfake, không bảo đảm kết luận chính xác tuyệt đối. Điều khoản dịch vụ được tài liệu module đề cập cũng cảnh báo rằng mẫu gửi lên có thể được chia sẻ với đối tác; vì vậy, không nên gửi dữ liệu cá nhân hoặc nội dung bí mật.

2.1.2. Hive AI-Generated & Deepfake Detection

Hive cung cấp công cụ và mô hình hỗ trợ phân tích hình ảnh, video và âm thanh để đánh giá khả năng nội dung được tạo bằng AI hoặc bị thao túng. Một số kết quả có thể kèm điểm tin cậy. Người dùng vẫn cần kiểm tra phạm vi của mô hình và không coi điểm số là bằng chứng xác nhận độc lập.

Hai công cụ trên là ví dụ để tìm hiểu phạm vi và cách diễn giải kết quả, không phải khẳng định rằng chúng luôn miễn phí, luôn khả dụng hoặc phù hợp với mọi loại dữ liệu. Tính năng, giới hạn sử dụng và điều khoản có thể thay đổi; cần kiểm tra thông tin hiện hành trước khi thực hành.

2.2. Quy trình sử dụng công cụ

1. Xác định loại tệp: ghi nhận mẫu cần kiểm tra là hình ảnh, video hay âm thanh.
2. Chọn công cụ: đối chiếu loại tệp với phạm vi phân tích mà công cụ hỗ trợ.
3. Kiểm tra quyền riêng tư: không tải lên tài liệu nội bộ, hình ảnh riêng tư, dữ liệu cá nhân hoặc nội dung chưa được phép chia sẻ. Ưu tiên mẫu do nhóm xây dựng hoặc mẫu đã được cho phép sử dụng.

4. Thực hiện kiểm tra: làm theo hướng dẫn của công cụ, nhập đường dẫn hoặc tải tệp lên nếu cần thiết.

5. Ghi nhận kết quả: lưu lại nhãn phân loại, điểm tin cậy hoặc thông tin giải thích mà công cụ cung cấp, nếu có.

6. Đối chiếu và đánh giá: kết hợp kết quả với thông tin nguồn, bối cảnh và bằng chứng khác trước khi quyết định cách xử lý.

Không nên tải một nội dung nhạy cảm lên nhiều dịch vụ khác nhau chỉ để tìm kết quả giống nhau. Gửi tệp cho nhiều bên có thể làm tăng nguy cơ dữ liệu bị lưu trữ hoặc chia sẻ ngoài dự kiến. Trước khi sử dụng, cần đọc điều khoản và chính sách quyền riêng tư của dịch vụ tương ứng.

Trong hoạt động học tập, nên ưu tiên mẫu minh họa do nhóm xây dựng hoặc có quyền sử dụng phù hợp. Nếu DEEPTRACE chưa tích hợp trực tiếp công cụ quét, hoạt động có thể được thực hiện bằng mô phỏng thao tác hoặc phân tích ảnh chụp kết quả mẫu; không nên mô tả rằng website tự động quét tệp nếu chức năng đó chưa được xây dựng.

Trước khi kiểm tra	Cần xác định
Loại nội dung	Là hình ảnh, video hay âm thanh?
Phạm vi công cụ	Công cụ có phân tích đúng loại nội dung và dấu hiệu đang cần kiểm tra không?
Quyền riêng tư	Tôi có quyền sử dụng mẫu này không? Dịch vụ xử lý và chia sẻ dữ liệu như thế nào?
Mục đích	Kết quả sẽ hỗ trợ quyết định nào và còn cần bằng chứng gì khác?

3. Đọc hiểu kết quả và kiểm chứng bổ sung

Sau khi sử dụng công cụ, người học cần hiểu đúng ý nghĩa của kết quả. Mỗi công cụ có thể sử dụng mô hình, dữ liệu huấn luyện, tiêu chí phân loại và cách thể hiện khác nhau. Vì vậy, các công cụ không nhất thiết cho cùng kết quả trên một mẫu nội dung.

3.1. Những yếu tố cần chú ý khi đọc kết quả

- Nhãn phân loại: Xác định công cụ đang đánh giá nội dung có khả năng được tạo bằng AI, có dấu hiệu Deepfake hay thuộc một nhóm khác. Không đồng nhất mọi nội dung AI tạo ra với nội dung giả mạo nhằm lừa đảo.

- Điểm tin cậy: Nếu có điểm số, hãy đọc theo cách giải thích của chính dịch vụ đó. Không tự động coi điểm số là xác suất chính xác tuyệt đối hoặc so sánh trực tiếp điểm số giữa các công cụ khác nhau.

- Phạm vi phân tích: Kiểm tra công cụ phân tích khuôn mặt, giọng nói, hình ảnh hay video. Kết quả chỉ phản ánh phạm vi công cụ hỗ trợ, không chứng minh toàn bộ nội dung là thật hoặc giả.

- Bằng chứng độc lập: Đối chiếu với nguồn ban đầu, tài khoản chính thức, thông tin từ các nguồn đáng tin cậy và bối cảnh sự kiện.

- Trạng thái chưa xác minh: Nếu căn cứ chưa đủ hoặc kết quả mâu thuẫn, cần tiếp tục kiểm tra và tránh đưa ra kết luận chắc chắn.

Ví dụ, Deepfake-o-meter được mô tả trong module là tập trung vào thao túng khuôn mặt trong video, không phân tích việc giả mạo giọng nói và không cam kết kết quả chính xác tuyệt đối. Nếu một video có hình ảnh chân thực nhưng giọng nói đáng ngờ, kết quả từ công cụ chỉ phân tích khuôn mặt không thể giải quyết toàn bộ nghi vấn.

Kết quả kiểm tra	Cách diễn giải	Hành động phù hợp
Công cụ báo có khả năng là Deepfake	Có dấu hiệu cần xem xét thêm; chưa phải bằng	Kiểm chứng nguồn, đối chiếu bằng chứng và tránh

	chứng duy nhất để kết luận.	chia sẻ như thông tin đã xác thực.
Công cụ không phát hiện Deepfake	Công cụ không tìm thấy dấu hiệu trong phạm vi phân tích của nó.	Không mặc định nội dung là thật; tiếp tục kiểm tra nếu có rủi ro.
Các công cụ cho kết quả khác nhau	Kết quả có thể phụ thuộc vào công cụ, mô hình hoặc mẫu đầu vào.	Kiểm tra phạm vi từng công cụ, tìm bằng chứng độc lập và giữ trạng thái chưa xác minh nếu cần.
Không thể phân tích hoặc không có kết quả	Chưa có đủ thông tin để đánh giá bằng công cụ đó.	Kiểm tra định dạng, chọn phương pháp phù hợp khác hoặc tìm hỗ trợ chuyên môn.

3.2. Kiểm chứng bổ sung bằng nguồn độc lập

Khi kết quả công cụ chưa đủ để đưa ra nhận định, hãy kiểm tra nguồn ban đầu và tìm thông tin từ những kênh độc lập đáng tin cậy. Với phát ngôn được cho là của một cá nhân hoặc tổ chức, có thể kiểm tra kênh chính thức và bối cảnh xuất hiện. Với yêu cầu chuyển tiền hoặc cung cấp thông tin, hãy xác minh trực tiếp qua thông tin liên hệ đã biết. Cần phân biệt giữa việc kiểm tra nội dung và việc xác minh yêu cầu hành động: ngay cả khi chưa xác định được nội dung có phải Deepfake hay không, người dùng vẫn có thể từ chối thực hiện một yêu cầu rủi ro chưa được xác minh.

Nguyên tắc quan trọng nhất là “không phát hiện” không đồng nghĩa với “đã chứng minh là thật”. Khi chứng cứ còn thiếu, lựa chọn hợp lý là tiếp tục kiểm chứng và hạn chế những hành động có thể gây thiệt hại.

4. Báo cáo, lưu giữ bằng chứng và hạn chế tác động của Deepfake

Khi gặp nội dung có dấu hiệu Deepfake gây hại, cách xử lý cần phù hợp với tính chất sự việc. Không phải trường hợp nào cũng cần sử dụng công cụ phát hiện; một số tình huống cần ưu tiên xác minh danh tính, bảo vệ tài khoản hoặc ngăn chặn thiệt hại trước mắt.

4.1. Lưu giữ bằng chứng cần thiết

Nếu nội dung có dấu hiệu lừa đảo, mạo danh hoặc xâm phạm quyền riêng tư, người học có thể lưu lại những thông tin cần thiết để phục vụ việc báo cáo:

- Đường dẫn bài đăng hoặc tài khoản phát tán nội dung.

- Thời gian tiếp nhận hoặc phát hiện nội dung.

- Ảnh chụp màn hình thể hiện nội dung, tài khoản và thông tin liên quan.

- Nội dung tin nhắn, yêu cầu chuyển tiền hoặc thông tin giao dịch có liên quan, nếu có.

Việc lưu giữ bằng chứng cần tôn trọng quyền riêng tư và không làm phát tán thêm nội dung gây hại. Không nên tải xuống, đăng lại hoặc chuyển tiếp hình ảnh, video nhạy cảm chỉ để chứng minh nội dung đó đáng ngờ. Chỉ lưu những thông tin cần thiết và sử dụng chúng cho mục đích báo cáo hoặc tìm kiếm hỗ trợ phù hợp.

4.2. Báo cáo nội dung đáng ngờ

Nếu nội dung xuất hiện trên mạng xã hội hoặc nền tảng trực tuyến, người dùng có thể sử dụng chức năng báo cáo của nền tảng và lựa chọn nhóm vi phạm phù hợp, chẳng hạn mạo danh, lừa đảo, thông tin gây hại hoặc xâm phạm quyền riêng tư. Nội dung báo cáo nên mô tả vấn đề cụ thể và cung cấp bằng chứng liên quan khi cần thiết.

Nếu đã cung cấp thông tin tài khoản, mã xác thực hoặc chuyển tiền theo yêu cầu của đối tượng đáng ngờ, cần nhanh chóng thực hiện các biện pháp hạn chế thiệt hại. Có thể liên hệ ngân hàng hoặc nhà cung cấp dịch vụ thanh toán qua kênh chính thức, bảo vệ tài khoản và lưu giữ thông tin giao dịch. Báo cáo nội dung trên nền tảng không thay thế cho các bước xử lý tài chính hoặc bảo mật tài khoản.

4.3. Tình huống thực hành

Một sinh viên nhận được đoạn ghi âm có giọng nói giống người thân. Người trong đoạn ghi âm cho biết đang gặp sự cố và yêu cầu sinh viên chuyển tiền ngay lập tức. Người gửi nhấn mạnh rằng không được gọi cho bất kỳ ai khác vì sự việc cần được giữ bí mật. Sinh viên chưa có bằng chứng xác nhận danh tính người gửi.

Bạn sẽ làm gì trong tình huống này?

A. Chuyển tiền ngay vì giọng nói giống người thân và tình huống có vẻ khẩn cấp.

B. Đăng đoạn ghi âm lên mạng xã hội để nhờ mọi người xác định đó có phải giọng giả hay không.

C. Tạm dừng chuyển tiền, gọi lại qua số điện thoại đã biết của người thân hoặc xác minh với một người đáng tin cậy khác.

D. Tải đoạn ghi âm lên nhiều công cụ phát hiện khác nhau rồi quyết định chuyển tiền theo kết quả.

Đáp án và giải thích

Đáp án phù hợp nhất là C. Tạm dừng chuyển tiền và xác minh qua kênh độc lập giúp giảm nguy cơ bị lừa đảo. Giọng nói giống người thân không đủ để xác nhận danh tính, đặc biệt khi người gửi gây áp lực về thời gian và yêu cầu giữ bí mật.

Phương án A có thể dẫn đến thiệt hại tài chính. Phương án B có thể làm phát tán thêm dữ liệu riêng tư và nội dung chưa được kiểm chứng. Phương án D không phù hợp vì tải dữ liệu nhạy cảm lên nhiều dịch vụ có thể làm tăng rủi ro về quyền riêng tư; kết quả công cụ cũng không nên là căn cứ duy nhất để quyết định chuyển tiền.

4.3.1. Dấu hiệu rủi ro cần nhận biết

- Yêu cầu chuyển tiền ngay hoặc thực hiện hành động nhạy cảm trong thời gian rất ngắn.

- Yêu cầu giữ bí mật, không liên hệ hoặc không xác minh với người khác.

- Danh tính chưa được xác nhận bằng một kênh liên lạc độc lập.

- Người gửi dùng giọng nói quen thuộc hoặc thông tin cá nhân để tạo cảm giác đáng tin.

Trong tình huống này, người học không cần chứng minh đoạn ghi âm là Deepfake mới có thể lựa chọn cách xử lý an toàn. Chỉ cần yêu cầu chuyển tiền chưa được xác minh và có dấu hiệu gây áp lực cũng đủ để tạm dừng và kiểm tra.

Tóm tắt: Quy trình xử lý nội dung đáng ngờ

Giai đoạn	Việc cần làm	Điều cần tránh
Phát hiện nghi vấn	Tạm dừng, nhận diện yêu cầu và mức độ rủi ro.	Vội chia sẻ, chuyển tiền hoặc cung cấp dữ liệu.
Kiểm tra	Xem xét nguồn, bối cảnh và xác minh qua kênh độc lập.	Tin hoàn toàn vào hình ảnh, giọng nói hoặc thông tin tự khai.
Dùng công cụ nếu phù hợp	Chọn công cụ đúng phạm vi; kiểm tra quyền riêng tư.	Tải dữ liệu nhạy cảm lên dịch vụ không rõ điều khoản hoặc nhiều công cụ.
Đánh giá kết quả	Đối chiếu bằng chứng; giữ trạng thái chưa xác minh khi chưa đủ căn cứ.	Coi điểm số hoặc một kết quả là kết luận cuối cùng.
Báo cáo và giảm thiệt hại	Lưu thông tin cần thiết, báo cáo nền tảng và liên hệ đơn vị liên quan khi cần.	Đăng lại nội dung gây hại hoặc làm lộ thêm dữ liệu.

Những nguyên tắc cần ghi nhớ

1. Tạm dừng trước khi thực hiện yêu cầu có rủi ro, đặc biệt là chuyển tiền, cung cấp mã xác thực hoặc tiết lộ dữ liệu cá nhân.

2. Xác minh danh tính qua kênh độc lập; không dựa hoàn toàn vào giọng nói hoặc hình ảnh.

3. Chọn công cụ dựa trên loại nội dung và phạm vi phân tích, không dựa vào tên gọi hoặc điểm số đơn thuần.

4. Đọc kết quả trong đúng phạm vi mà công cụ hỗ trợ. "Không phát hiện" không có nghĩa là "đã chứng minh là thật".

5. Kiểm tra điều khoản và chính sách quyền riêng tư trước khi tải nội dung lên dịch vụ trực tuyến.

6. Lưu giữ bằng chứng cần thiết, báo cáo phù hợp và tránh phát tán thêm nội dung có nguy cơ gây hại.

7. Nếu thiệt hại đã xảy ra, nhanh chóng bảo vệ tài khoản và liên hệ tổ chức tài chính hoặc dịch vụ liên quan qua kênh chính thức.

Tổng kết Module 4

Module 4 giúp người học chuyển kiến thức về Deepfake thành hành động cụ thể. Khi gặp nội dung đáng ngờ, hãy tạm dừng, kiểm tra nguồn và bối cảnh, sử dụng công cụ khi phù hợp, đối chiếu kết quả với bằng chứng độc lập rồi lựa chọn cách xử lý.

Công cụ phát hiện có thể hỗ trợ nhưng không thay thế việc xác minh. Người học cần hiểu phạm vi phân tích, không diễn giải điểm số như sự thật tuyệt đối và giữ trạng thái chưa xác minh khi bằng chứng chưa đủ. Đồng thời, cần cân nhắc quyền riêng tư trước khi tải dữ liệu lên dịch vụ trực tuyến.

Nếu nội dung có nguy cơ gây hại, hãy lưu giữ thông tin cần thiết, báo cáo qua kênh phù hợp và tìm hỗ trợ khi cần. Nếu đã có giao dịch hoặc tài khoản bị ảnh hưởng, hãy nhanh chóng liên hệ tổ chức liên quan qua kênh chính thức. Mục tiêu cuối cùng là

giảm thiểu rủi ro và lựa chọn hành động an toàn, không phải cố gắng tự mình kết luận chính xác mọi Deepfake.

Tài liệu tham khảo

1. Federal Trade Commission. (2023, September 27). Scammers Use Fake Emergencies To Steal Your Money. https://consumer.ftc.gov/articles/scammers-use-fake-emergencies-steal-your-money
2. Federal Trade Commission. (2023, March 20). Scammers use AI to enhance their family emergency schemes. https://consumer.ftc.gov/comment/180311
3. Deepfake-o-meter. (n.d.). FAQ - Deepfake-o-meter Scanner. https://Deepfake-o-meter.ai/us/faq/index.html
4. Deepfake-o-meter. (n.d.). Terms of Services. https://Deepfake-o-meter.ai/terms-of-services/
5. Hive. (n.d.). AI-Generated Content Detection. https://thehive.ai/apis/ai-generated-media